

Trabajo Final Integrador

Fundamentos de Ciencia de Datos

Proyecto integrador de Ciencia de Datos aplicado al análisis de datos del parque automotor argentino

1. Fundamentación

El presente trabajo final integrador tiene como propósito desarrollar un proyecto completo de Ciencia de Datos, recorriendo todas las etapas principales del proceso: *búsqueda y recolección de datos, preparación y almacenamiento, análisis exploratorio, formulación de preguntas, construcción de modelos de aprendizaje automático, visualización efectiva de resultados y publicación* del proyecto en un sitio web.

El proyecto deberá trabajar principalmente con datos abiertos vinculados al parque automotor argentino, tomando como fuente inicial los datos provistos por la **Dirección Nacional de los Registros Nacionales de la Propiedad del Automotor —DNRPA—**, especialmente aquellos relacionados con inscripciones [2], robos y recuperos [1].

El objetivo será construir una solución analítica completa que permita comprender un problema, formular preguntas relevantes, obtener evidencia a partir de los datos y comunicar los resultados de manera clara, visual e interactiva.

2. Objetivo general

Desarrollar un proyecto integral de Ciencia de Datos que permita analizar, modelar, visualizar y comunicar información relevante a partir de datos abiertos del parque automotor argentino, dejando como producto final un reporte, una presentación y un sitio web funcional donde se publiquen los principales resultados.

3. Descripción general del proyecto

Cada grupo (2 integrantes) deberá desarrollar un proyecto de Ciencia de Datos utilizando datos del DNRPA y, opcionalmente, otras fuentes complementarias.

El proyecto deberá partir de una problemática concreta. Por ejemplo:

- ¿Existen patrones temporales o geográficos en los robos de vehículos?
- ¿Qué relación existe entre inscripciones, robos y recuperos?
- ¿Qué provincias o regiones presentan mayores variaciones en determinadas variables?
- ¿Se pueden identificar zonas o períodos con mayor riesgo relativo?
- ¿Es posible predecir una categoría, tendencia o comportamiento a partir de los datos disponibles?
- ¿Qué variables permiten explicar mejor ciertos fenómenos observados?
- ¿Cómo se puede comunicar esta información de manera clara a un público no técnico?

La problemática definitiva deberá surgir de una combinación entre el interés del grupo, la disponibilidad de datos y los resultados obtenidos durante el análisis exploratorio.

4. Etapas obligatorias del trabajo

Etapas obligatorias del trabajo

Etapas obligatorias del trabajo

El grupo deberá formular de manera clara el problema que desea abordar.

Deberán incluir:

- Tema general del proyecto.

- Problema específico que se desea analizar.
- Justificación de la importancia del problema.
- Público destinatario del análisis: ciudadanos, organismos públicos, investigadores, aseguradoras, municipios, etc.
- Preguntas iniciales que guiarán el trabajo.

Ejemplo:

“El proyecto busca analizar la evolución de los robos y recuperos de vehículos en Argentina entre distintos períodos, identificando patrones temporales y geográficos que permitan comprender en qué zonas y momentos se concentran los eventos registrados.”

Etapas 2: Recolección y descripción de datos

El grupo deberá identificar, descargar y documentar los conjuntos de datos utilizados.

Deberán especificar:

- Fuente de los datos.
- Enlace de descarga o acceso.
- Fecha de consulta o descarga.
- Formato de los archivos: CSV, Excel, JSON, API, etc.
- Cantidad de registros.
- Cantidad de atributos.
- Descripción de las variables.
- Tipos de datos.
- Período temporal cubierto.
- Nivel geográfico disponible: país, provincia, localidad, registro seccional, etc.

Opcionalmente, podrán incorporar fuentes complementarias, por ejemplo:

- Datos poblacionales del INDEC.
- Datos geográficos de provincias o departamentos.
- Información socioeconómica.
- Datos de patentamientos.
- Datos de aseguradoras, si fueran abiertos.
- Mapas o archivos geográficos públicos.

La incorporación de fuentes adicionales será valorada siempre que esté justificada y correctamente documentada.

Etapas 3: Limpieza, transformación y almacenamiento

En esta etapa deberán preparar los datos para el análisis.

Se espera que realicen tareas como:

- Detección y tratamiento de valores faltantes.
- Revisión de registros duplicados.
- Conversión de tipos de datos.
- Tratamiento de fechas.
- Creación de nuevas variables.
- Agrupamientos por provincia, año, mes u otra dimensión relevante.
- Integración de múltiples archivos.
- Generación de un dataset final limpio.

Además, deberán definir una estrategia simple de almacenamiento. Puede ser:

- Archivos CSV procesados.
- Base de datos relacional.
- Archivos JSON.

- Estructura de carpetas organizadas para el proyecto.

Etapla 4: Análisis Exploratorio de Datos

El análisis exploratorio deberá permitir comprender el comportamiento general de los datos antes de aplicar modelos.

Deberán incluir, como mínimo:

- Análisis de cantidad de registros.
- Distribución de variables relevantes.
- Evolución temporal.
- Comparación entre provincias o regiones.
- Identificación de valores extremos o atípicos.
- Análisis de relaciones entre variables.
- Agrupamientos y rankings.
- Tablas resumen.
- Visualizaciones exploratorias.

Se recomienda trabajar con preguntas como:

- ¿Qué variables presentan mayor variabilidad?
- ¿Qué provincias concentran mayor cantidad de eventos?
- ¿Existen tendencias crecientes o decrecientes?
- ¿Hay estacionalidad?
- ¿Existen meses, años o regiones con comportamientos particulares?
- ¿Qué datos parecen inconsistentes o requieren precaución?

El análisis exploratorio deberá estar acompañado de interpretaciones. No alcanza con insertar gráficos. Cada gráfico debe responder alguna pregunta.

Etapla 5: Formulación de preguntas analíticas

Luego del análisis exploratorio, el grupo deberá reformular o ajustar sus preguntas iniciales.

Deberán presentar entre **3 y 5 preguntas principales** que el proyecto intentará responder.

Ejemplos:

1. ¿Cómo evolucionaron los robos de vehículos por provincia durante el período analizado?
2. ¿Qué relación existe entre cantidad de inscripciones y cantidad de robos registrados?
3. ¿Qué provincias presentan mayor proporción de recuperos respecto de robos?
4. ¿Existen patrones mensuales o estacionales en los eventos registrados?
5. ¿Es posible clasificar provincias según perfiles similares de comportamiento automotor?

Etapla 6: Aplicación de Machine Learning

El proyecto deberá incluir al menos **una** técnica de Machine Learning aplicada de manera coherente con el problema y justificada correctamente.

La técnica seleccionada dependerá del tipo de datos y de la pregunta planteada.

Algunas posibilidades:

Opción A: Clustering

Agrupar provincias, períodos o registros según características similares.

Ejemplos:

- Agrupar provincias según cantidad de robos, recuperos e inscripciones.

- Identificar perfiles regionales.
- Comparar clusters con variables geográficas o demográficas.

Opción B: Clasificación

Predecir una categoría a partir de variables disponibles.

Ejemplos:

- Clasificar una provincia o período como de “alta”, “media” o “baja” incidencia.
- Clasificar registros según riesgo relativo.
- Predecir si una observación pertenece a un grupo determinado.

Opción C: Regresión

Predecir un valor numérico.

Ejemplos:

- Estimar la cantidad de robos a partir de inscripciones, provincia, año o mes.
- Predecir cantidad de recuperos.
- Modelar tendencias temporales.

Requisitos mínimos de Machine Learning

El grupo deberá incluir:

- Justificación de la técnica seleccionada.
- Variables utilizadas.
- Preparación de datos para el modelo.
- División entre entrenamiento y prueba, si corresponde.
- Entrenamiento del modelo.
- Evaluación mediante métricas adecuadas.
- Interpretación de resultados.
- Limitaciones del modelo.

Se evaluará que el modelo esté bien elegido, correctamente aplicado e interpretado.

Eta 7: Visualización interactiva y comunicación de resultados

El proyecto deberá incluir visualizaciones claras, efectivas e idealmente interactivas.

Podrán utilizar herramientas como:

Las visualizaciones deberán ayudar a responder las preguntas del proyecto.

Se valorará la inclusión de:

- Gráficos temporales.
- Mapas.
- Tablas interactivas.
- Filtros por año, provincia, tipo de evento u otra variable.
- Tarjetas resumen.
- Rankings.
- Comparaciones regionales.
- Gráficos derivados del modelo de Machine Learning.

Cada visualización deberá tener:

- Título claro.
- Variables correctamente etiquetadas.
- Escalas comprensibles.
- Colores adecuados.
- Interpretación asociada.
- Diseño legible.

Etapla 8: Desarrollo y despliegue en sitio web

Plantee un servicio web (api) donde el producto final deberá quedar disponible en un sitio web.

El sitio deberá funcionar como una presentación pública del proyecto, orientada a comunicar los principales hallazgos.

Podrá desarrollarse mediante:

- HTML, CSS y Bootstrap.
- GitHub Pages.
- Netlify.
- Streamlit Community Cloud.
- Render.
- Vercel.
- Otra alternativa justificada.

El sitio deberá incluir, como mínimo:

1. **Portada del proyecto**
 - Título.
 - Integrantes.
 - Materia.
 - Año.
 - Breve descripción.
2. **Problema abordado**
 - Contexto.
 - Preguntas principales.
 - Justificación.
3. **Datos utilizados**
 - Fuentes.
 - Descripción de variables.
 - Período analizado.
 - Limitaciones.
4. **Análisis exploratorio**
 - Principales gráficos.
 - Hallazgos relevantes.
5. **Modelo de Machine Learning**
 - Técnica utilizada.
 - Variables.
 - Resultados.
 - Métricas.
 - Interpretación.
6. **Visualizaciones interactivas**
 - Gráficos, mapas o dashboards embebidos.
7. **Conclusiones**
 - Respuestas a las preguntas iniciales.
 - Hallazgos principales.
 - Limitaciones.
 - Posibles mejoras futuras.

6. Entregables obligatorios

1. Notebook o scripts de análisis

Puede ser en Google Colab, Jupyter Notebook o scripts Python.

Debe incluir:

- Carga de datos.
- Limpieza y transformación.
- Análisis exploratorio.
- Visualizaciones.
- Aplicación del modelo.
- Evaluación.
- Comentarios explicativos.

2. Reporte final en PDF

El reporte deberá tener estructura formal.

Extensión sugerida: entre **8 y 15 páginas**.

Debe incluir:

1. Portada.
2. Introducción.
3. Definición del problema.
4. Objetivos.
5. Descripción de los datos.
6. Metodología.
7. Limpieza y preparación de datos.
8. Análisis exploratorio.
9. Modelo de Machine Learning.
10. Visualizaciones y sitio web.
11. Resultados.
12. Conclusiones.
13. Limitaciones.
14. Trabajo futuro.
15. Referencias y fuentes de datos.

3. Presentación oral

La presentación tendrá una duración máxima de **10 minutos**.

Deberá incluir:

- Problema abordado.
- Datos utilizados.
- Principales decisiones metodológicas.
- Hallazgos del análisis exploratorio.
- Modelo aplicado.
- Visualizaciones principales.
- Sitio web publicado.
- Conclusiones.